Заключительный аналитический отчёт по пяти этапам проекта: подготовка данных, классификация, A/B-тест, кластеризация и модель склонности к покупке.

Анализ маркетинговых кампаний и покупателей спортивного магазина

Главное решение

Не масштабировать первую email-кампанию на основании имеющегося сравнения: группы покупателей существенно различались ещё до запуска. Для новой кампании в городе 1188 использовать модель склонности к покупке как инструмент отбора аудитории и проверять эффект отдельным корректным A/B-тестом.

Четыре подтверждённых результата

Направление	Результат
Подготовка данных	104437 покупателей страны 32; 780113 корректных строк покупок, без пропусков в итоговой таблице.
Восстановление пола	15651 пропущенных значений восстановлено; F1 на тестовой выборке = 1,0.
Email A/B, дни 5–16	Выручка/участника: 22450 (контроль) и 26628 (тест); но стартовые группы не сопоставимы.
Сегментация и прогноз	3 кластера; модель товара «Брюки мужские Demix»: ROC-AUC = 0,730; lift топ-10% = 3,65.

Период

Период наблюдений: дни 0-58. Сведения о реальных расходах на рассылку и себестоимости товаров не используются, поэтому оценка ROI здесь не производится.

1. Источники и обработка данных

Исходная база SQLite содержит таблицы **personal_data**, **personal_data_coeffs** и **purchases**. Отдельный **personal_data.csv.gz** восстанавливает часть профилей без поля пола; обычный CSV повторяет сжатый файл. В исходных покупках 786260 строк.

Проверка	Результат
Профили в базе	89241
Восстановленные профили без пола	15748
Покупатели страны 32	104437
Покупки страны 32	780117 до проверки стоимости
Не положительная стоимость	4 строки исключены
Итоговая таблица покупок	780113 строк; нет пропусков

Как обработаны признаки

- Оставлена только страна с кодом 32; объединение профилей и коэффициентов выполнено по id.
- Название товара приведено к нижнему регистру, удалены лишние пробелы; категория – первое слово названия.
- «Чёрный» и «черный» приведены к общему виду; в сочетаниях через / выделен первый цвет; отсутствующий цвет помечен «не указан».
- Пропущенный product_sex закодирован как -1 («не указан»); первоначальный показатель base_sale сохранён как факт скидки при покупке.
- Профили не удалялись из-за отсутствия покупок в отдельном периоде: это важно для расчёта конверсии по участникам кампании.

Выходные данные

Сформированы таблица покупок с восстановленным полом, таблица клиентов, метки кластеров и список клиентов города 1188 с оценками модели для ранжирования. Каждая строка итоговой таблицы покупок сохраняет ID покупателя и необходимые товарные признаки.

2. Бинарная классификация: восстановление пола

Задача: восстановить неизвестный признак gender у клиентов из добавленного CSV. Обучение проводилось на 88786 клиентах страны 32 с известным полом. Данные разделены случайно на обучение и тест (80/20) с сохранением пропорции классов.

Признаки и алгоритм

Случайный лес (RandomForestClassifier) использует возраст, образование, personal_coef, число и сумму покупок, долю скидок, доли покупок товаров для мужчин и женщин. Отбор и проверка разделены; предсказания пропусков выполнены после проверки теста.

Показатель на тесте	Значение
Тестовых клиентов	17758
F1-score	1,0
Precision / Recall	1,0 / 1,0
Ошибки классификации	0 из 17758
Восстановлено gender	15651

Почему качество очень высокое

В имеющихся записях personal_coef практически кодирует пол: наблюдаемые значения коэффициента для gender = 0 и gender = 1 не смешиваются. Поэтому F1 = 1,0 корректен именно для этой выборки, но не означает, что модель идеально работает на произвольных данных. В заполненной части страны 32 нет значений personal_coef, отсутствовавших среди размеченных клиентов.

Проверка: для класса 0 корректно определены 7576 клиентов, для класса 1 – 10182. Распределение и кодирование пола сохранены как в исходной таблице, без догадок о значении меток 0 и 1.

3. Проверка первой email-кампании: A/B-тест

Кампания проходила с 5-го по 16-й день. Тестовая группа – получатели персональной скидки, контрольная – сопоставленные по замыслу покупатели без предложения. В файлах по 5000 уникальных ID; после ограничения страной 32 – 4 984 в тесте и 4960 в контроле.

Метрика, дни 5-16	Контроль	Тест
Покупали, чел.	4960	4775
Конверсия в покупку	100%	95,81%
Выручка / участника	22450	26628
Товаров / участника	4,02	5,02
Средняя цена товара	5591	5305

Разница в конверсии: -4,19 п. п. ($p < 0{,}001$, критерий хи-квадрат); разница в выручке на участника: +18,61% ($p < 0{,}001$, t-test). В расчёте участвуют и клиенты без покупок.



Проверка соотношения численности групп (хи-квадрат): $p = 0{,}810$, дисбаланс по размеру отсутствует. Однако равный размер ещё не подтверждает сопоставимость групп по поведению.

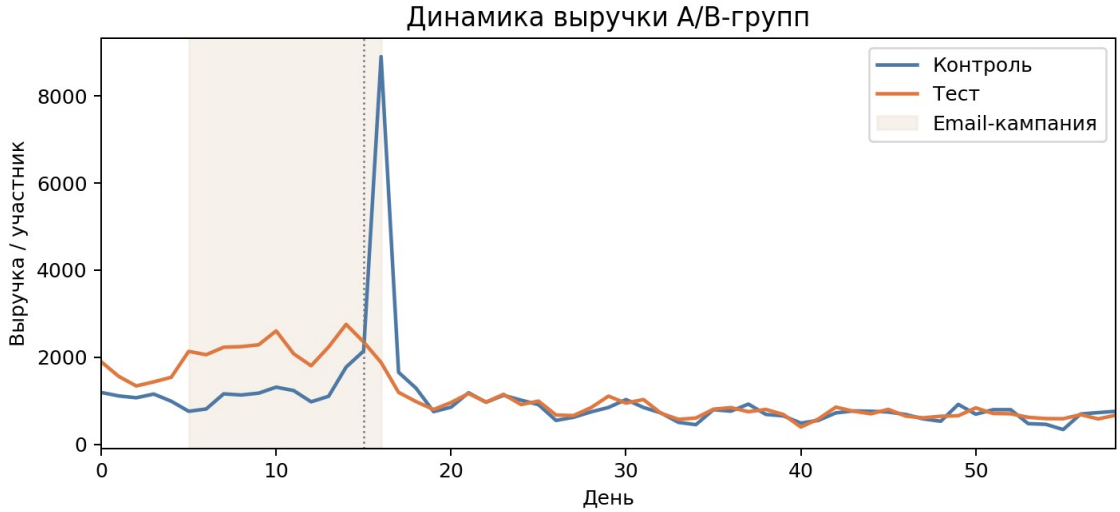
4. Можно ли назвать email-кампанию успешной?

Нельзя доказать причинный эффект по этому A/B: ещё до отправки писем группы отличались по частоте покупок и выручке. В дни 0-4 покупали 29,62% участников контроля и 68,78% участников теста. Средняя выручка до кампании: 5503 против 7756, $p < 0{,}001$.

Дополнительные проверки

Проверка	Конверсия: контроль → тест	Выручка на участника: контроль → тест
Без города 1134	100,0% → 96,05%	22269 → 26527
Без 15-го дня	100,0% → 93,54%	20311 → 24280

Город 1134 исключали из-за второй, билбордной кампании, действовавшей 15-го и 45-го числа. Проверка не устраняет уже существующие различия групп.



Бизнес-вывод по кампании

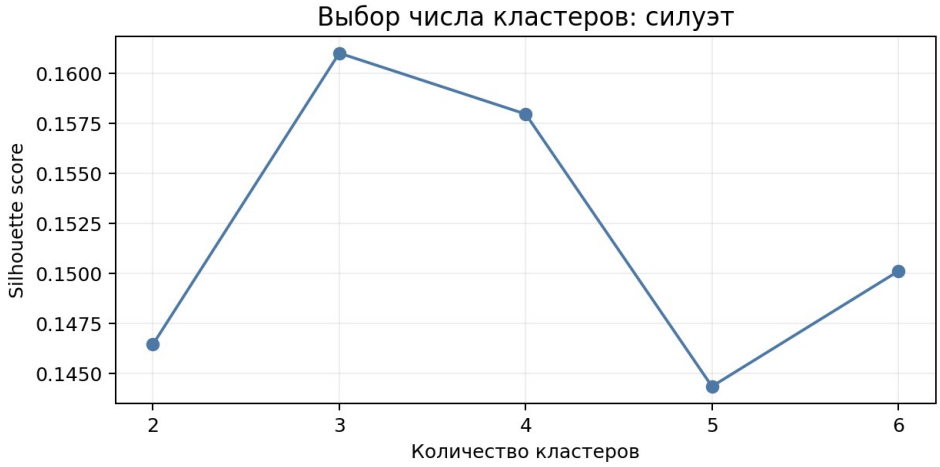
В период кампании тестовая группа имела более высокую выручку на участника, но это не является доказательством, что именно скидка вызвала рост. Решение: не объявлять рассылку эффективной и не расширять её автоматически. Для проверки эффекта случайно распределить сопоставимых клиентов и заранее выбрать основную метрику – выручку на назначенного клиента.

5. Кластеризация покупателей

Объекты кластеризации – 104437 покупателей страны 32. Использованы возраст, частота и сумма покупок, доля купленных товаров со скидкой, доли мужских/женских товаров и давность последней покупки. Перед K-средним числовые признаки стандартизированы, частота и траты логарифмированы.

Проверены k = 2…6 на случайной выборке из 10000 покупателей. Лучшее значение силуэта – 0,161 при k = 3; полученные три кластера применены ко всей аудитории. Силуэт невысок, поэтому сегменты рассматриваются как рабочее, а не однозначное разбиение.

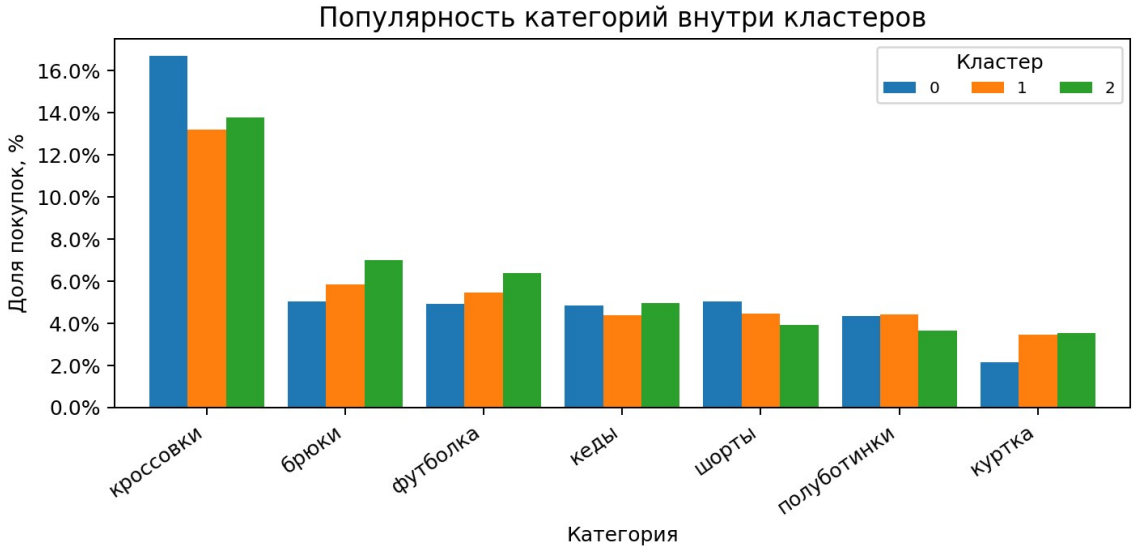
Кластер / размер	Профиль	Доля покупок со скидкой
0 / 40066	3,34 товара и 15,9 тыс. суммы на клиента; реже покупают	25,29%
1 / 37656	12,48 товара и 77,5 тыс.; высокая активность	32,69%
2 / 26715	6,60 товара и 25,0 тыс.; больше женских товаров	44,17%



Скидка означает факт скидки среди совершённых покупок. Без данных о показах и отказах она не показывает, сколько дополнительных покупок вызвали скидки.

6. Товарные предпочтения и работа с сегментами

Самая распространённая категория во всех сегментах – кроссовки. Далее различаются категории: для кластера 0 характерны шорты и брюки; для 1 – брюки и футболки; для 2 – брюки, футболки, сандалии и кеды. Выводы основаны на частоте покупок, а не на доходности товаров.



Сегмент	Что рекомендовать
0 – редкие покупки	Небольшие подборки популярной обуви и шорт; тестировать персональные предложения для возвращения.
1 – активные	Кроссовки, брюки и футболки; комплекты и сопутствующие товары для увеличения среднего чека.
2 – скидочные	Обувь и женские категории; аккуратные промо и проверка маржинальности скидок перед расширением.

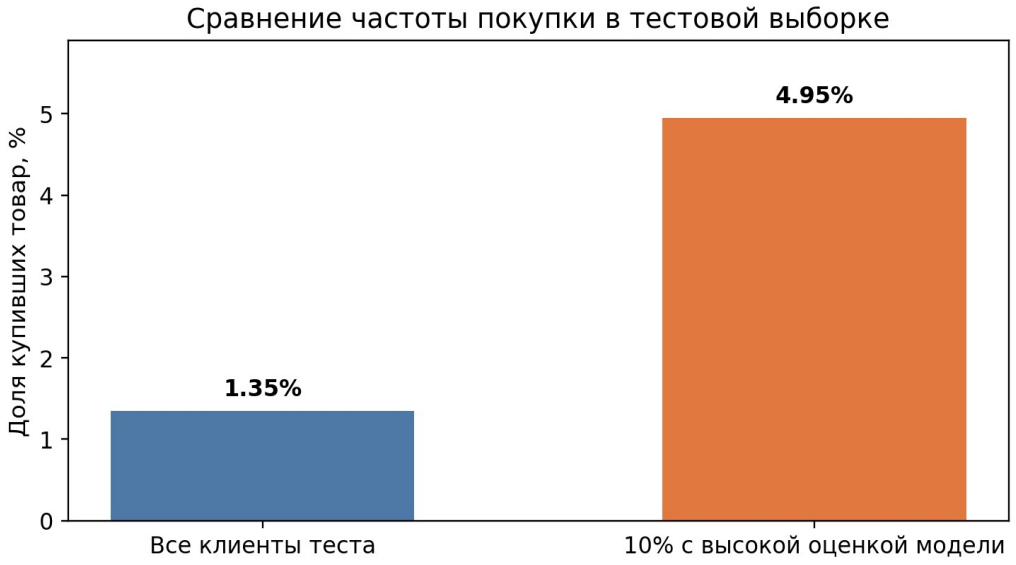
Сегменты можно пересчитывать после появления новых покупок. Предложения по товарам опираются на реально наблюдаемые предпочтения, а не на причинный эффект скидки.

7. Модель склонности к покупке товара для города 1188

Выбран конкретный товар «Брюки мужские Demix». Таргет – покупка этого товара в дни 31-58 (1 – была покупка, 0 – не было). Признаки – профиль клиента, коэффициент и только покупки за дни 0-30, а также принадлежность к первой рассылке и город второй кампании. Тем самым сведения из будущего не попадают в признаки.

Для обучения исключён город 1188; оставшиеся клиенты разделены на обучающую и тестовую выборки 80/20 с сохранением доли покупок. Случайный лес обучен на 73599 клиентах и проверен на 18400. Для 12438 клиентов города 1188 составлен список, упорядоченный по оценке модели.

Показатель на тестовой выборке	Значение
ROC-AUC	0,730
Клиентов в тестовой выборке	18400
Доля купивших в тесте	1,35%
Доля купивших в верхних 10% прогноза	4,95%
Отношение 4,95% / 1,35%	3,65 раза



На исторических данных модель помогает ранжировать клиентов, но не оценивает эффект самой коммуникации. Выход модели используется как сравнительная оценка интереса к товару.

Для запуска кампании необходимо обновить историю и проверить результат на случайно выделенной контрольной группе.

8. План действий и заключение

Рекомендации заказчику

- Не масштабировать первую email-скидку как доказанно успешную. Сначала провести повторное A/B-тестирование с корректным случайным распределением.
- Использовать три сегмента для подготовки разных предложений: возвращение редких покупателей, комплекты для активных, контролируемые скидки для чувствительных к промо.
- Для города 1188 построить адресный список по оценке интереса к товару «Брюки мужские Demix» и начать проверку с клиентов, оказавшихся в верхней части рейтинга.
- Проверить рассылку адресного предложения на случайно разделённых группах, сравнивая выручку на назначенного клиента и конверсию. После измерения эффекта решить, стоит ли расширять кампанию.

Что важно для правильной интерпретации

База содержит только покупателей, а не всех посетителей магазина: поэтому модель применима прежде всего к существующим клиентам. Влияние скидки на вероятность покупки нельзя вывести из доли скидочных покупок. Исторический прогноз также не заменяет эксперимента по измерению эффекта рекламы. Вторая кампания учитывалась как возможное смешение при анализе первой, её самостоятельный причинный эффект не оценивался.

Техническая проверяемость

В ноутбуке сохранены просмотр структуры файлов, очистка, тест модели пола, восстановление 15651 значений, расчёт A/B с проверкой исходной сопоставимости, выбор k для кластеризации и качество прогноза на отложенной выборке. Таблицы клиентов, покупок, кластеров и рейтинг города 1188 записаны в отдельные CSV.

Итог

Результат проекта – подготовленная клиентская база, три интерпретируемых сегмента и рабочий способ приоритизировать аудиторию нового предложения. Ограничение по первой рассылке найдено при проверке исходной сопоставимости групп, поэтому вывод об её эффективности намеренно не делается.